

视觉SLAM中的矩阵李群

基础

王 京
UAV514

提纲

- 3D刚体运动表示
- 3D运动李群
- 增量和导数
- 在视觉SLAM中的应用

提纲


- 3D刚体运动表示
- 3D运动李群
- 增量和导数
- 在视觉SLAM中的应用

3D刚体运动

- 2D旋转

- 刚体旋转等价于坐标系旋转，**右手定则**-旋转正方向
- 坐标系 \mathcal{F} 的单位正交基向量 $\mathbf{e}_1, \mathbf{e}_2 \in \mathbb{R}^2$
- 旋转前坐标系表示 $\mathcal{F}^w = [\mathbf{e}_1^w, \mathbf{e}_2^w]$
- 旋转后坐标系表示 $\mathcal{F}^c = [\mathbf{e}_1^c, \mathbf{e}_2^c]$
- 正交基之间的线性组合关系

$$\begin{aligned}\mathbf{e}_1^c &= \cos \theta \cdot \mathbf{e}_1^w + \sin \theta \cdot \mathbf{e}_2^w \\ \mathbf{e}_2^c &= -\sin \theta \cdot \mathbf{e}_1^w + \cos \theta \cdot \mathbf{e}_2^w\end{aligned}$$



$$[\mathbf{e}_1^c, \mathbf{e}_2^c] = [\mathbf{e}_1^w, \mathbf{e}_2^w] \cdot \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \stackrel{\text{def}}{=} [\mathbf{e}_1^w, \mathbf{e}_2^w] \cdot R_\theta$$

- \mathcal{F}^w 经过旋转 R_{wc} 得到了 \mathcal{F}^c

$$\mathcal{F}^c = \mathcal{F}^w \cdot R_\theta = \mathcal{F}^w \cdot R_{wc}$$

$$R_{wc} = R_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

3D刚体运动

- 3D刚体固连坐标系 \mathcal{F} 的旋转

- 刚体旋转等价于坐标系旋转
- 坐标系 \mathcal{F} 的单位正交基 $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3 \in \mathbb{R}^3$
- 旋转前坐标系表示 $\mathcal{F}^w = [\mathbf{e}_1^w, \mathbf{e}_2^w, \mathbf{e}_3^w]$
- 旋转后坐标系表示 $\mathcal{F}^c = [\mathbf{e}_1^c, \mathbf{e}_2^c, \mathbf{e}_3^c]$
- 正交基之间的线性组合关系


$$\mathbf{e}_1^c = r_{11}\mathbf{e}_1^w + r_{21}\mathbf{e}_2^w + r_{31}\mathbf{e}_3^w$$

$$\mathbf{e}_2^c = r_{12}\mathbf{e}_1^w + r_{22}\mathbf{e}_2^w + r_{32}\mathbf{e}_3^w$$

$$\mathbf{e}_3^c = r_{13}\mathbf{e}_1^w + r_{23}\mathbf{e}_2^w + r_{33}\mathbf{e}_3^w$$

$$[\mathbf{e}_1^c, \mathbf{e}_2^c, \mathbf{e}_3^c] = [\mathbf{e}_1^w, \mathbf{e}_2^w, \mathbf{e}_3^w] \cdot \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{bmatrix} \Leftrightarrow \mathcal{F}^c = \mathcal{F}^w \cdot R_{wc}$$

- 含义： \mathcal{F}^w 经过旋转 R_{wc} 得到了 \mathcal{F}^c
- ($R_{wc}R_{wc}^T = I$ 并且 $\det(R_{wc}) = 1$)



3D刚体运动


- 旋转作用下的固定点坐标变换
 - 3D空间中的固定点 P
 - P 在 \mathcal{F}^w 中坐标 $p_w = [x_1, y_1, z_1]^T$
 - P 在 \mathcal{F}^c 中坐标 $p_c = [x_2, y_2, z_2]^T$
 - 不同坐标满足

$$P := \mathcal{F}^w \cdot p_w = \mathcal{F}^c \cdot p_c$$

$$\mathcal{F}^w \cdot p_w = \mathcal{F}^c \cdot p_c = \mathcal{F}^w \cdot R_{wc} \cdot p_c \Rightarrow p_w = R_{wc} \cdot p_c$$

$$p_c = R_{wc}^{-1} \cdot p_w = R_{wc}^T \cdot p_w \stackrel{\text{def}}{=} R_{cw} \cdot p_w$$

$$\mathcal{F}^c = \mathcal{F}^w \cdot R_{wc} \quad R_{wc} = (\mathcal{F}^w)^{-1} \cdot \mathcal{F}^c$$



3D刚体运动

- 刚体固连坐标系旋转 **vs** 固定点坐标变换

- 刚体固连坐标系旋转

$$\mathcal{F}^c = \mathcal{F}^w \cdot R_{wc}$$

- 固定点在不同坐标系下变换

$$p_c = R_{cw} \cdot p_w = R_{wc}^{-1} \cdot p_w \quad (= R_{wc}^T \cdot p_w)$$

- 表示矩阵互为逆矩阵

- 例：计算机体姿态欧拉角时，用 $R_{wc}(R_b^n?)$

- 北东地系下，偏航 ψ -俯仰 θ -滚转 ϕ 顺序的机体欧拉角

$$\mathcal{F}^c = \mathcal{F}^w \cdot R_\psi R_\theta R_\phi = \mathcal{F}^w \cdot R_{wc}, \quad p_c = R_{cw} p_w = R_{wc}^T p_w$$

$$R_{wc} = \begin{bmatrix} C_\psi & -S_\psi & \\ S_\psi & C_\psi & \\ & & 1 \end{bmatrix} \begin{bmatrix} C_\theta & & S_\theta \\ & 1 & \\ -S_\theta & & C_\theta \end{bmatrix} \begin{bmatrix} 1 & & \\ & C_\phi & -S_\phi \\ & S_\phi & C_\phi \end{bmatrix}$$

3D刚体运动

- 考虑刚体平移

- 除了旋转，坐标系原点 O 有平移
- 在 \mathcal{F}^w 下 O_c 坐标即为 $t_{wc} \in \mathbb{R}^3$

- 固定点 P 的坐标变换？
- 向量 $V_{O_w \rightarrow P} = V_{O_w \rightarrow O_c} + V_{O_c \rightarrow P}$
- 上式的 基向量x坐标 形式

$$\mathcal{F}^w \cdot p_w = \mathcal{F}^w \cdot t_{wc} + \mathcal{F}^c \cdot p_c$$


- 由于 $\mathcal{F}^c = \mathcal{F}^w \cdot R_{wc}$

$$p_w = t_{wc} + R_{wc} \cdot p_c$$

- 齐次坐标： $\check{p}_c = [p_c; 1]$

$$\check{p}_w = \begin{bmatrix} R_{wc} & t_{wc} \\ 0 & 1 \end{bmatrix} \cdot \check{p}_c \stackrel{\text{def}}{=} T_{wc} \cdot \check{p}_c$$

- $T_{wc}, T_{cw} \in SE(3)$, $T_{wc} = T_{cw}^{-1}$



3D刚体运动

- 位姿更新的左乘、右乘

- 假设 \mathcal{F}^w 是固定的参考坐标系， \mathcal{F}^c 在运动相机上
- 相机微小运动，固连坐标系运动到 $\mathcal{F}^{c'}$ ，点坐标

$$\check{p}_{c'} = T_{c'c} \check{p}_c$$

- \mathcal{F}^w 到 \mathcal{F}^c 的固定点坐标变换矩阵


$$\begin{aligned}\check{p}_{c'} &= T_{c'c} \check{p}_c = T_{c'c} T_{cw} \check{p}_w = T_{c'w} \check{p}_w \\ T_{c'w} &= T_{c'c} \cdot T_{cw}\end{aligned}$$

- \mathcal{F}^w 到 $\mathcal{F}^{c'}$ 的刚体运动矩阵

$$T_{wc'} = T_{wc} \cdot T_{cc'}$$

- 从 \mathcal{F}^w 到 $\mathcal{F}^{c'}$

- $T_{cw} \in SE(3)$ 的更新是左乘一个变化量（点坐标变换）
- $T_{wc} \in SE(3)$ 的更新是右乘一个变化量（刚体坐标系运动）
- 数学本质一样，物理含义不同，对左右乘的数学处理公式不同



提纲

- 3D刚体运动表示
- 3D运动李群 TUM的MVG课程思路
- 增量和导数
- 在视觉SLAM中的应用

3D运动李群

- 李群基本数学定义

- 群：集合 G + 操作符 $\circ: G \circ G \rightarrow G$ ，满足：
 - 封闭性： $g_1 \circ g_2 \in G, \forall g_1, g_2 \in G$
 - 结合律： $(g_1 \circ g_2) \circ g_3 = g_1 \circ (g_2 \circ g_3), \forall g_1, g_2, g_3 \in G$
 - 单位元： $\exists e \in G: e \circ g = g \circ e = g, \forall g \in G$
 - 可逆性： $\exists g^{-1} \in G: g \circ g^{-1} = g^{-1} \circ g = e, \forall g \in G$
- 李群：群 + 光滑
 - 群操作符的映射，是光滑映射
 - （整数群 \mathbb{Z} 不是李群）
- 李群的李代数：向量空间 + 双线性操作符（李括号）
 - 数学空间，一个数域上的代数（algebra over a field）
 - 操作符4个性质：封闭性、双线性、alternating、雅克比等式（略）
 - 李群在单位元素处的切空间

3D运动李群

- 常用李群举例
 - 一般线性群： $GL(n)$
 - 所有 $n \times n$ 的可逆矩阵
 - 操作符为矩阵乘法
 - 单位元是单位矩阵 $I_{n \times n}$
 - 正交群： $O(n) \subset GL(n)$
 - $O(n) = \{R \in GL(n) | R^T R = I\}$
 - 特殊正交群： $SO(n) \subset O(n) \subset GL(n)$
 - $SO(n) = \{R \in GL(n) | R^T R = I, \det(R) = +1\}$
 - 欧几里得群： $E(n) \subset GL(n+1)$
 - $E(n) = \left\{ \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \mid R \in O(n), t \in \mathbb{R}^n \right\}$
 - 特殊欧几里得群： $SE(n) \subset GL(n+1)$
 - $SE(n) = \left\{ \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \mid R \in SO(n), t \in \mathbb{R}^n \right\}$

3D运动李群

- 反对称矩阵(skew-symmetric matrix)

- 向量叉乘 $a = [a_1, a_2, a_3]^T \in \mathbb{R}^3$ 和 $b = [b_1, b_2, b_3]^T \in \mathbb{R}^3$

$$a \times b = \begin{bmatrix} a_2 b_3 - a_3 b_2 \\ a_3 b_1 - a_1 b_3 \\ a_1 b_2 - a_2 b_1 \end{bmatrix} = \begin{bmatrix} 0 & -a_3 & a_2 \\ a_3 & 0 & -a_1 \\ -a_2 & a_1 & 0 \end{bmatrix} \cdot b \stackrel{\text{def}}{=} [a]_{\times} b$$

- $[a]_{\times}$ 是反对称矩阵, $[a]_{\times}^T = -[a]_{\times}$

- 反对称矩阵与 \mathbb{R}^3 元素 一一对应

- 另一符号定义, $\hat{w} \stackrel{\text{def}}{=} [w]_{\times}$

- 向量 $w = \phi \cdot u \in \mathbb{R}^3$, $\phi = |w|$ 为模长, 性质:

- $\hat{w}w = w \times w = 0$
- $\hat{w}^2 = \hat{w}\hat{w} = \phi^2 \hat{u}\hat{u} = ww^T - \phi^2 I$
- $\hat{w}^3 = \hat{w} \cdot \hat{w}\hat{w} = -\phi^2 \hat{w}$

3D运动李群

- 3D特殊正交群 $SO(3)$


- $SO(3) = \{R \in GL(3) | R^T R = I, \det(R) = +1\}$
- R 代表3D旋转运动，是 $SO(3)$ 的元素
- 假设一个smooth path：
 - R 随时间 τ 连续（光滑）变化， $R(\tau)$
 - $R(0) = I$ ，即0时刻没有旋转
- 对 $R(\tau)R(\tau)^T = I$ 关于 τ 求导

$$\begin{aligned}(R(\tau)\dot{R}(\tau)^T) &= R(\tau)\dot{R}(\tau)^T + \dot{R}(\tau)R(\tau)^T = 0 \\ \Rightarrow \dot{R}(\tau)R(\tau)^T &= -R(\tau)\dot{R}(\tau)^T = -[\dot{R}(\tau)R(\tau)^T]^T\end{aligned}$$

- $\dot{R}(\tau)R(\tau)^T$ 是一个反对称矩阵 Ω ，满足 $\Omega^T = -\Omega$
- $\exists \omega \in \mathbb{R}^3$ s.t. $\hat{\omega} = \dot{R}(\tau)R(\tau)^T$

$$\dot{R}(\tau) = \hat{\omega} \cdot R(\tau)$$

- 注： $(R(\tau)^T \dot{R}(\tau)) = 0 \Rightarrow \dot{R}(\tau) = R(\tau) \cdot \hat{\omega}$ 是另一种表示



<https://3dmagicmodels.com/shop/3d-models/sports-and-hobbies/outdoor-games/cricket-ball-3d-model/>

3D运动李群

- 3D特殊正交群 $SO(3)$

- $\dot{R}(\tau) = \hat{\omega} \cdot R(\tau) \sim \dot{f}(x) = a \cdot f(x)$

- 矩阵指数函数的导数

- 矩阵（方阵）指数函数

$$\exp(M) = \sum_{n=0}^{+\infty} \frac{M^n}{n!}$$

- 与标量指数区别： $\exp(A+B) = \exp(A) \cdot \exp(B) \Leftrightarrow AB = BA$

- $\dot{R}(\tau) = \hat{\omega} \cdot R(\tau) \Rightarrow R(\tau) = \exp(\hat{\omega}\tau) \cdot R(0)$

- 令 $w = \omega\tau$ ，且 $R(0) = I$

$$R = \exp(\hat{w})$$

- 角速度

- $\dot{R}(\tau) = \hat{\omega} \cdot R(\tau)$ ， $\omega = [\omega_1, \omega_2, \omega_3]^T \in \mathbb{R}^3$ 和刚体角速度有关

3D运动李群

- 3D特殊正交群 $SO(3)$

- $R = \exp(\hat{w})$

$$\exp(\hat{w}) = \sum_{n=0}^{+\infty} \frac{\hat{w}^n}{n!}$$

- 展开

$$\exp(\hat{w}) = \sum_{n=0}^{+\infty} \frac{\hat{w}^n}{n!} = I + \hat{w} + \frac{\hat{w}^2}{2!} + \frac{\hat{w}^3}{3!} + \frac{\hat{w}^4}{4!} + \dots$$

- $w = |w| \cdot u \stackrel{\text{def}}{=} \phi u$, 反对称矩阵性质 $\hat{w}^2 = \phi^2 \hat{u} \hat{u}$, $\hat{w}^3 = -\phi^3 \hat{u}$

- 简化

$$\begin{aligned} \exp(\hat{w}) &= I + \left(\phi - \frac{\phi^3}{3!} + \frac{\phi^5}{5!} - \frac{\phi^7}{7!} + \dots \right) \hat{u} + \left(\frac{\phi^2}{2!} - \frac{\phi^4}{4!} + \frac{\phi^6}{6!} - \frac{\phi^8}{8!} + \dots \right) \hat{u} \hat{u} \\ &= I + \sin \phi \cdot \hat{u} + (1 - \cos \phi) \cdot \hat{u} \hat{u} \end{aligned}$$

- 即(Rodrigues公式) https://en.wikipedia.org/wiki/Rodrigues%27_rotation_formula

$$R = \exp(\hat{w}) = I + \sin(|w|) \cdot \frac{\hat{w}}{|w|} + (1 - \cos(|w|)) \cdot \frac{\hat{w} \hat{w}}{|w|^2}$$

3D运动李群

- $SO(3)$ 的李代数 $\mathfrak{so}(3)$

$$R = \exp(\hat{w}) = \exp(\hat{w}\tau), \quad \dot{R} = \hat{w} \cdot R$$

- $SO(3)$ 与 \hat{w} 之间是指数映射关系
- \dot{R} 代表 R 处的导数 \sim 切向量
- 所有切向量组成： R 处切空间


- 在单位元处， $R = I, \dot{R} = \hat{w} \sim \hat{w}$
- 各 \hat{w} 张成了单位元处的切空间

- $\mathfrak{so}(3)$ 定义：

- 向量空间： $\mathfrak{so}(3) = \{W = \hat{w} \in \mathbb{R}^{3 \times 3}, w \in \mathbb{R}^3\}$
- 数域：实数域 \mathbb{R}
- 李括号： $[W_1, W_2] = W_1 W_2 - W_2 W_1$

- $\mathfrak{so}(3)$ 就是 $SO(3)$ 在单位元处的切空间

最小表示 $w \in \mathbb{R}^3 \rightarrow \rightarrow$ 李代数 $\hat{w} \rightarrow \rightarrow$ 李群元素 $R = \exp \hat{w}$



Strasdat, H. (2012). *Local accuracy and global consistency for efficient visual slam* (Doctoral dissertation, Department of Computing, Imperial College London).

3D运动李群

- $SE(3)$ 与李代数 $\mathfrak{se}(3)$

- $SE(3)$ 元素 T

$$T = \left\{ \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \mid R \in SO(3), t \in \mathbb{R}^3 \right\}$$

- $\mathfrak{se}(3)$ 元素 $\hat{\xi}$

- 向量空间： $\mathfrak{se}(3) = \{\Xi = \hat{\xi} \in \mathbb{R}^{4 \times 4}, \xi = [w; v] \in \mathbb{R}^6, w \in \mathbb{R}^3, v \in \mathbb{R}^3\}$
 - 数域：实数域 \mathbb{R}
 - 李括号： $[\Xi_1, \Xi_2] = \Xi_1 \Xi_2 - \Xi_2 \Xi_1$

- 其中的操作符 $\hat{\cdot}$ 定义为

$$\hat{\xi} = \begin{bmatrix} \hat{w} & v \\ 0 & 0 \end{bmatrix}, \quad \xi = [w, v]^T$$

- 下面说明这个操作符的来源及 T 与 w, v 的关系

??? 最小表示 $\xi = [w; v] \rightarrow \rightarrow$ 李代数 $\hat{\xi} \rightarrow \rightarrow$ 李群元素 $T = \exp \hat{\xi}$

3D运动李群

- $SE(3)$ 与李代数 $\mathfrak{se}(3)$

$$T = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \Rightarrow T^{-1} = \begin{bmatrix} R^T & -R^T t \\ 0 & 1 \end{bmatrix}$$

- 类似 $SO(3)$ ，假设随时间 τ 有 $T(\tau)$ 并且 $T(0) = I$

- 关于时间的导数与逆相乘

$$\dot{T}(\tau)T(\tau)^{-1} = \begin{bmatrix} \dot{R} & \dot{t} \\ 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} R^T & -R^T t \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} \dot{R}R^T & \dot{t} - \dot{R}R^T t \\ 0 & 0 \end{bmatrix}$$

- 如果用 $T(\tau)^{-1}\dot{T}(\tau)$?

- $\exists \omega \in \mathbb{R}^3, s.t. \dot{R}R^T = [\omega]_{\times}$ ，因此

$$\dot{T}(\tau) = \begin{bmatrix} \hat{\omega} & \dot{t} - \hat{\omega}t \\ 0 & 0 \end{bmatrix} T(\tau) \Rightarrow T(\tau) = \exp \begin{bmatrix} \hat{\omega}\tau & (\dot{t} - \hat{\omega}t)\tau \\ 0 & 0 \end{bmatrix} \cdot T(0)$$

- 令 $w = \omega\tau, v = \dot{t}\tau - \hat{\omega}t \in \mathbb{R}^3$ ，并且有 $T(0) = I$ ，指数映射

$$T(\tau) = \exp \begin{bmatrix} \hat{w} & v \\ 0 & 0 \end{bmatrix} \stackrel{\text{def}}{=} \exp \hat{\xi}$$

3D运动李群

- $SE(3)$ 与李代数 $\mathfrak{se}(3)$
 - 指数函数的泰勒级数

$$\begin{aligned} T = \exp(\hat{\xi}) &= \sum_{n=0}^{+\infty} \frac{\hat{\xi}^n}{n!} = \sum_{n=0}^{+\infty} \frac{1}{n!} \begin{bmatrix} \hat{w} & v \\ 0 & 0 \end{bmatrix}^n \\ &= \begin{bmatrix} \sum_{n=0}^{+\infty} \frac{1}{n!} \hat{w}^n & \sum_{n=0}^{+\infty} \frac{1}{(n+1)!} \hat{w}^n v \\ 0 & 1 \end{bmatrix} \end{aligned}$$

- 化简形式

$$T = \exp(\hat{\xi}) = \begin{bmatrix} \exp(\hat{w}) & J \cdot v \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} R & J \cdot v \\ 0 & 1 \end{bmatrix}$$

- 其中 J 见

- TUM的MVG公开课[1]第二讲 公开课地址 <https://vision.in.tum.de/teaching/ss2016/mvg2016>
 - 或Barfoot的教材[4]

最小表示 $\xi = [w; v] \rightarrow \rightarrow$ 李代数 $\hat{\xi} \rightarrow \rightarrow$ 李群元素 $T = \exp \hat{\xi}$

3D运动李群

- $Sim(3)$ 与其李代数

- 相似变换：平移+旋转+缩放（各向同性）

- $Sim(3)$ 元素 S

$$S = \begin{bmatrix} sR & t \\ 0 & 1 \end{bmatrix}, \quad R \in SO(3), s \in \mathbb{R}, t \in \mathbb{R}^3$$

- 类似 $SO(3)$ ，假设随时间 τ 有 $S(\tau)$ 并且 $S(0) = I$

$$\dot{S} \cdot S^{-1} = \begin{bmatrix} \frac{\dot{s}}{s} RR^T + \dot{R} R^T & \dot{t} - \frac{\dot{s}}{s} RR^T t - \dot{R} R^T t \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} \frac{\dot{s}}{s} I + \hat{\omega} & \dot{t} - \frac{\dot{s}}{s} t - \hat{\omega} t \\ 0 & 0 \end{bmatrix}$$

- 其中 $\exists \omega \in \mathbb{R}^3$ s.t. $\hat{\omega} = \dot{R} R^T \in \mathfrak{so}(3)$

$$\dot{S} = \begin{bmatrix} \frac{\dot{s}}{s} I + \hat{\omega} & \dot{t} - \frac{\dot{s}}{s} t - \hat{\omega} t \\ 0 & 0 \end{bmatrix} \cdot S$$

- 积分结果

$$S(\tau) = \exp \left(\begin{bmatrix} \frac{\dot{s}}{s} I + \hat{\omega} & \dot{t} - \frac{\dot{s}}{s} t - \hat{\omega} t \\ 0 & 0 \end{bmatrix} \cdot \tau \right) \cdot S(0)$$

3D运动李群

- $Sim(3)$ 与其李代数

$$S(\tau) = \exp \left(\begin{bmatrix} \frac{\dot{s}}{s} \tau I + \hat{\omega} \tau & t\tau - \frac{\dot{s}}{s} \tau t - \hat{\omega} \tau t \\ 0 & 0 \end{bmatrix} \right) \cdot S(0)$$

- 令 $\omega\tau = w, \frac{\dot{s}}{s}\tau = \sigma, v = t\tau - \sigma t - \hat{w}t$, 并且 $S(0) = I$

- 定义 $\zeta = [w; v; \sigma] \in \mathbb{R}^7$

- 李代数及hat操作符：

$$\hat{\cdot}_{Sim(3)} : \zeta = [w, v, \sigma] \in \mathbb{R}^7 \rightarrow \hat{\zeta} = \begin{bmatrix} \sigma I + \hat{w} & v \\ 0 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 3}$$

- 指数映射

$$S = \exp(\hat{\zeta}) = \sum_{n=0}^{+\infty} \frac{1}{n!} \begin{bmatrix} \sigma I + \hat{w} & v \\ 0 & 0 \end{bmatrix}^n = \begin{bmatrix} e^{\sigma} \cdot R & J \cdot v \\ 0 & 1 \end{bmatrix}$$

- 同样用泰勒级数计算。其中 J 参考Strasdat的博士学位论文5.2节

- $\zeta = [w; v; \sigma]$ 与 s, R, t

$$s = e^{\sigma}, R = \exp(\hat{w}), t = Jv$$

最小表示 $\zeta = [w; v; \sigma] \rightarrow \rightarrow$ 李代数 $\hat{\zeta} \rightarrow \rightarrow$ 李群元素 $S = \exp \hat{\zeta}$

参考博士论文：Strasdat, H. (2012). *Local accuracy and global consistency for efficient visual slam* (Doctoral dissertation, Department of Computing, Imperial College London).

提纲

- 3D刚体运动表示
- 3D运动李群
- 增量和导数
- 在视觉SLAM中的应用

增量和导数

- BCH公式 (Baker-Campbell-Hausdorff , 见wikipedia) https://en.wikipedia.org/wiki/Baker%E2%80%93Campbell%E2%80%93Hausdorff_formula

– 对于标量的指数函数

$$\exp(a) \exp(b) = \exp(a + b)$$

– 对于矩阵指数函数不同

$$\log(\exp X \exp Y) = \sum_{n>0} \frac{(-1)^{n-1}}{n} \sum_{\substack{r_i+s_i>0 \\ 1 \leq i \leq n}} \frac{(\sum_{i=1}^n (r_i + s_i))^{-1}}{r_1! s_1! \cdots r_n! s_n!} [X^{r_1} Y^{s_1} X^{r_2} Y^{s_2} \cdots X^{r_n} Y^{s_n}]$$

$$[X^{r_1} Y^{s_1} X^{r_2} Y^{s_2} \cdots X^{r_n} Y^{s_n}] = [\underbrace{X, [X, \dots [X,}_{r_1} \underbrace{[Y, [Y, \dots [Y,}_{s_1} \dots \underbrace{[X, [X, \dots [X,}_{r_n} \underbrace{[Y, [Y, \dots Y]]}_{s_n} \dots]]$$

$$\begin{aligned} Z(X, Y) &= \log(\exp X \exp Y) \\ &= X + Y + \frac{1}{2}[X, Y] + \frac{1}{12}([X, [X, Y]] + [Y, [Y, X]]) \\ &\quad - \frac{1}{24}[Y, [X, [X, Y]]] \\ &\quad - \frac{1}{720}([Y, [Y, [Y, [Y, X]]]] + [X, [X, [X, [X, Y]]]]) \\ &\quad + \frac{1}{360}([X, [Y, [Y, [Y, X]]]] + [Y, [X, [X, [X, Y]]]]) \\ &\quad + \frac{1}{120}([Y, [X, [Y, [X, Y]]]] + [X, [Y, [X, [Y, X]]]]) + \cdots \end{aligned}$$

增量和导数

- $SO(3)$ 和 $\mathfrak{so}(3)$ 增量
 - 1. $\mathfrak{so}(3)$ 加增量 (谢晓佳@ZJU)
 - $R_0 = \exp(\hat{w}_0), R = \exp(\hat{w}_0 + \Delta\hat{w})$
 - $R \approx \exp(J_l(\hat{w}_0) \cdot \Delta\hat{w}) \cdot \exp(w_0) = \exp(J_l(\hat{w}_0) \cdot \Delta\hat{w}) \cdot R_0$
 - $R \approx \exp(w_0) \cdot \exp(J_r(\hat{w}_0) \cdot \Delta\hat{w}) = R_0 \cdot \exp(J_r(\hat{w}_0) \cdot \Delta\hat{w})$
 - 左右导数 ($|w| = \phi$) 通过BCH公式求得
 - $J_l(\hat{w}) = \frac{\sin \phi}{\phi} I + \left(1 - \frac{\sin \phi}{\phi}\right) aa^T + \frac{1 - \cos \phi}{\phi} \hat{a}$
 - $J_r(\hat{w}) = \frac{\sin \phi}{\phi} I + \left(1 - \frac{\sin \phi}{\phi}\right) aa^T - \frac{1 - \cos \phi}{\phi} \hat{a}$
 - GTSAM 4.0(IMU-preintegration on manifold论文)中用到计算误差影响
 - 2. $SO(3)$ 乘增量
 - $R_0 = \exp(\hat{w}_0), R = \Delta R \cdot R_0 = \exp(\Delta\hat{w}) \cdot R_0$
 - 上面是左乘更新方式
 - 对于右乘更新, 定义为 $R = R_0 \cdot \exp(\Delta\hat{w})$
 - VSLAM基本用此种更新方式
 - (主要介绍)

增量和导数

- 点坐标关于增量的雅克比 (大部分的**基础**)

- 齐次坐标变换 : $\tilde{x} = T\tilde{y} = [x; 1]$

- 位姿 T 微小变化 : $T_{\text{trans}} = \exp(\hat{\xi}) \cdot T$

- **变换后坐标 : $\tilde{x}_{\text{trans}} = \exp(\hat{\xi}) \cdot T\tilde{y} = \exp(\hat{\xi}) \cdot \tilde{x}$**

- $\xi = [w; v] \rightarrow 0_{6 \times 1}$ 时 , $\exp(\hat{\xi}) \approx I + \hat{\xi}$

- 变换后坐标关于增量 $\xi \rightarrow 0$ 的雅克比

$$\begin{aligned} \frac{\partial[\tilde{x}_{\text{trans}}]}{\partial \xi} \Big|_{\xi=0} &= \frac{\partial[\exp(\hat{\xi}) \cdot \tilde{x}]}{\partial \xi} \Big|_{\xi=0} \approx \frac{\partial[(I + \hat{\xi}) \cdot \tilde{x}]}{\partial \xi} \Big|_{\xi=0} \\ &= \frac{\partial[\hat{\xi} \cdot \tilde{x}]}{\partial \xi} \Big|_{\xi=0} = \frac{\partial \left[\begin{bmatrix} \hat{w} & v \\ 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} x \\ 1 \end{bmatrix} \right]}{\partial \xi} \Big|_{\xi=[w;v]=0} = \frac{\partial \begin{bmatrix} \hat{w}x + v \\ 0 \end{bmatrix}}{\partial [w; v]} \Big|_{\xi=[w;v]=0} \\ &= \frac{\partial \begin{bmatrix} -\hat{x}w + v \\ 0 \end{bmatrix}}{\partial [w; v]} = \begin{bmatrix} -\hat{x} & I_{3 \times 3} \\ 0 & 0 \end{bmatrix} \end{aligned}$$

- 对于非齐次坐标 : **$\frac{\partial x(\exp(\hat{\xi})T, y)}{\partial \xi} \Big|_{\xi=0} = \frac{\partial [x_{\text{trans}}]}{\partial \xi} \Big|_{\xi=0} = [-\hat{x} \quad I_{3 \times 3}]$**

增量和导数

- 更麻烦的推导

- $\xi = [\xi_1, \xi_2, \dots, \xi_6]$ 的**每一维分别考虑**

$$\frac{\partial[\exp(\hat{\xi}) \cdot T]}{\partial \xi_k} \Big|_{\xi=0} = \frac{\partial[\exp(t\hat{e}_k) \cdot T]}{\partial t} \Big|_{t=0}$$

- 其中 e_k 是第 k 维单位向量, 如 $e_2 = [0, 1, 0, 0, 0, 0]$

$$\frac{\partial[\exp(t\hat{e}_k) \cdot T]}{\partial t} \Big|_{t=0} = [\hat{e}_k \cdot \exp(t\hat{e}_k) \cdot T] \Big|_{t=0} = \hat{e}_k \cdot T \stackrel{\text{def}}{=} G_k T$$

- 其中 G_k 是 $\mathfrak{se}(3)$ 的generators

$$G_1 = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, \quad G_2 = \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \\ -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, \quad G_3 = \begin{bmatrix} 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$
$$G_4 = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, \quad G_5 = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, \quad G_6 = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

- 整体雅克比: 4x4x6张量

$$\frac{\partial[\exp(\hat{\xi}) \cdot T]}{\partial \xi} \Big|_{\xi=0} = [G_1 T, G_2 T, G_3 T, G_4 T, G_5 T, G_6 T]$$

增量和导数

- 更麻烦的推导-续

- 整体雅克比：4x4x6张量

$$\frac{\partial [\exp(\hat{\xi}) \cdot T]}{\partial \xi} \Big|_{\xi=0} = [G_1 T, G_2 T, G_3 T, G_4 T, G_5 T, G_6 T]$$

- 点坐标变换关于增量的雅克比

$$\begin{aligned} \frac{\partial [\exp(\hat{\xi}) \cdot T \check{y}]}{\partial \xi} \Big|_{\xi=0} &= [G_1 T \check{y}, G_2 T \check{y}, G_3 T \check{y}, G_4 T \check{y}, G_5 T \check{y}, G_6 T \check{y}] \\ &= [G_1 \check{x}, G_2 \check{x}, G_3 \check{x}, G_4 \check{x}, G_5 \check{x}, G_6 \check{x}] = \begin{bmatrix} -\hat{x} & I_{3 \times 3} \\ 0 & 0 \end{bmatrix} \end{aligned}$$

- Generators : $G_k \stackrel{\text{def}}{=} \widehat{e_k}$

$$\begin{aligned} G_1 &= \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, & G_2 &= \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \\ -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, & G_3 &= \begin{bmatrix} 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \\ G_4 &= \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, & G_5 &= \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, & G_6 &= \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} \end{aligned}$$

提纲

- 3D刚体运动表示
- 3D运动李群
- 增量和导数
- 在视觉SLAM中的应用

视觉SLAM中的应用

- 重投影误差的雅克比——相机模型

- 相机内参矩阵 $K = \begin{bmatrix} f_u & 0 & c_u \\ 0 & f_v & c_v \end{bmatrix}$


- 相机坐标系中3D点坐标 $x = [x_1, x_2, x_3]^T \in \mathbb{R}^3$

- 相机投影模型


$$\hat{z}(x) = \text{proj}(x) = K \cdot \frac{1}{x_3} x$$

- 投影位置关于 x 的雅克比

$$\frac{\partial \hat{z}(x)}{\partial x} = \begin{bmatrix} \frac{f_u}{x_3} & 0 & -\frac{f_u x_1}{x_3^2} \\ 0 & \frac{f_v}{x_3} & -\frac{f_v x_2}{x_3^2} \end{bmatrix}$$



视觉SLAM中的应用



- 重投影误差的雅克比

- 相机位姿 T 和3D点 y
- y 在图像中观测位置 z ，估计位置 $\hat{z}(T, y)$
- 最小化重投影误差：

$$e(T, y) = z - \hat{z}(T, y) = z - \text{proj}([I_{3 \times 3} \quad 0_{3 \times 1}] \cdot T \tilde{y})$$

- 误差关于位姿增量 ξ 的雅克比


$$\begin{aligned} \frac{\partial e(\exp(\hat{\xi}) T, y)}{\partial \xi} \Big|_{\xi=0} &= - \frac{\partial \hat{z}(x)}{\partial x} \Big|_{\tilde{x}=T\tilde{y}} \cdot \frac{\partial x(\exp(\hat{\xi}) T, y)}{\partial \xi} \Big|_{\xi=0} \\ &= - \begin{bmatrix} \frac{f_u}{x_3} & 0 & -\frac{f_u x_1}{x_3^2} \\ 0 & \frac{f_v}{x_3} & -\frac{f_v x_2}{x_3^2} \end{bmatrix} \cdot [-\hat{x} \quad I_{3 \times 3}] \quad x: \text{相机系中点坐标} \end{aligned}$$

- 误差关于3D点 y 的雅克比

$$\frac{\partial e(T, y)}{\partial y} = - \frac{\partial \hat{z}(x)}{\partial x} \cdot \frac{\partial x(T, y)}{\partial y} = - \frac{\partial \hat{z}(x)}{\partial x} \cdot R$$


视觉SLAM中的应用

- 最小化重投影误差计算Sim3
 - 单目SLAM，没有绝对尺度
 - 误差累积可能导致尺度“漂移”
 - 现象：运行较长路径回到之前的地方，之前局部地图和当前局部地图的尺度不同



- 上图
 - 两组局部地图点实际对应相同的3D点
 - 但在局部地图中尺度不一样。
- SVD+RANSAC可以求解两组点的Sim3
- ORBSLAM中，进一步OptimizeSim3()。但尺度会影响重投影误差？

视觉SLAM中的应用



- 最小化重投影误差计算Sim3

- 两者间变换 S_{cl}

$$S_{cl} = \begin{bmatrix} s_{cl}R_{cl} & t_{cl} \\ 0 & 1 \end{bmatrix}, s_{cl} \in \mathbb{R}, R_{cl} \in SO(3), t_{cl} \in \mathbb{R}^3$$

$$S_{lc} = S_{cl}^{-1} = \begin{bmatrix} \frac{1}{s_{cl}}R_{cl}^T & -\frac{1}{s_{cl}}R_{cl}^T t_{cl} \\ s_{cl} & 0 \\ 0 & 1 \end{bmatrix} \stackrel{\text{def}}{=} \begin{bmatrix} s_{lc}R_{lc} & t_{lc} \\ 0 & 1 \end{bmatrix}$$

- 点坐标变换 $y_c = s_{cl}R_{cl}y_l + t_{cl}$

- 优化计算策略

- y_l 通过 S_{cl} 变换到 KF_{cur} 并投影，重投影误差

$$e_c = z_c - \hat{z}_c = z_c - \text{proj}(s_{cl}R_{cl}y_l + t_{cl})$$

- y_c 通过 S_{lc} 投影到 KF_{loop} 的重投影误差

$$e_l = z_l - \hat{z}_l = z_l - \text{proj}(s_{lc}R_{lc}y_c + t_{lc})$$

- 通过调整 $S_{cl} \in Sim(3)$ 使所有这些残差之和最小

- 每对地图点对应同一个被优化量 S_{cl} ，g2o中（正、逆投影）两条边

视觉SLAM中的应用

- 最小化重投影误差计算Sim3

$$e_c = z_c - \hat{z}_c = z_c - \text{proj}(s_{cl}R_{cl}y_l + t_{cl})$$

$$e_l = z_l - \hat{z}_l = z_l - \text{proj}(s_{lc}R_{lc}y_c + t_{lc})$$

- e_c 关于 y_l 的雅克比

$$\frac{\partial e_c(S_{cl}, y_l)}{\partial y_l} = -\frac{\partial \hat{z}_c(x)}{\partial x} \cdot \frac{\partial x(S_{cl}, y_l)}{\partial y_l} \Big|_{x=s_{cl}R_{cl}y_l+t_{cl}} = -\frac{\partial \hat{z}_c(x)}{\partial x} \cdot s_{cl}R_{cl}$$

- e_l 关于 y_c 的雅克比

$$J_{y_c}^{e_l} \stackrel{\text{def}}{=} \frac{\partial e_l(S_{lc}, y_c)}{\partial y_c} = -\frac{\partial \hat{z}_l(x)}{\partial x} \cdot \frac{\partial x(S_{lc}, y_c)}{\partial y_c} \Big|_{x=s_{lc}R_{lc}y_c+t_{lc}} = -\frac{\partial \hat{z}_l(x)}{\partial x} \cdot s_{lc}R_{lc}$$

- 位姿更新： $S_{cl} \leftarrow S_{cl}(\zeta) \stackrel{\text{def}}{=} \exp(\hat{\zeta}) S_{cl}$

- $\zeta = [w; v; \sigma] \in \mathbb{R}^7, w, v \in \mathbb{R}^3, \sigma \in \mathbb{R}, \quad \hat{\zeta} = \begin{bmatrix} \sigma I + \hat{w} & v \\ 0 & 0 \end{bmatrix}$

- e_c, e_l 关于 $\hat{\zeta}$ 的雅克比？

视觉SLAM中的应用

- 最小化重投影误差计算Sim3

- e_c 关于 S_{cl} 增量 $\hat{\zeta}$ 的雅克比

- $\zeta \rightarrow 0$ 时, $\exp(\hat{\zeta}) \approx I + \hat{\zeta} = I + \begin{bmatrix} \sigma I + \hat{w} & v \\ 0 & 0 \end{bmatrix}$

$$\left. \frac{\partial e_c(S_{cl}(\hat{\zeta}), y_l)}{\partial \zeta} \right|_{\zeta=0} = - \left. \frac{\partial \hat{z}_c(x)}{\partial x} \right|_{\tilde{x}=S_{cl} \cdot \tilde{y}_l} \cdot \left. \frac{\partial x(S_{cl}(\hat{\zeta}), y_l)}{\partial \zeta} \right|_{\zeta=0}$$

- 令 $S_{cl} \cdot \tilde{y}_l = \tilde{x}$, 后一项

$$\left. \frac{\partial x(S_{cl}(\hat{\zeta}), y_l)}{\partial \zeta} \right|_{\zeta=0} = [I_{3 \times 3} \quad 0_{3 \times 1}] \cdot \left. \frac{\partial \exp(\hat{\zeta}) S_{cl} \cdot \tilde{y}_l}{\partial \zeta} \right|_{\zeta=0}$$

$$= [I \quad 0] \cdot \left. \frac{\partial \left(x + \begin{bmatrix} \sigma x + \hat{w}x & v \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x \\ 1 \end{bmatrix} \right)}{\partial [w; v; \sigma]} \right|_{[w; v; \sigma]=0} = [-\hat{x} \quad I_{3 \times 3} \quad x]$$

- 整体代入：尺度会影响重投影误差？

$$\left. \frac{\partial e_c(S_{cl}(\zeta), y_c)}{\partial \zeta} \right|_{\zeta=0} = \begin{bmatrix} -\frac{f_u}{x_3} & 0 & \frac{x_1 f_u}{x_3^2} & \frac{x_1 x_2}{x_3^2} f_u & -\left(1 + \frac{x_1^2}{x_3^2}\right) f_u & \frac{x_2}{x_3} f_u \\ 0 & -\frac{f_v}{x_3} & \frac{x_2 f_v}{x_3^2} & \left(1 + \frac{x_2^2}{x_3^2}\right) f_v & -\frac{x_1 x_2}{x_3^2} f_v & -\frac{x_1}{x_3} f_v \end{bmatrix} \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

视觉SLAM中的应用

- 最小化重投影误差计算Sim3

- e_c 关于 S_{cl} 增量 $\hat{\zeta}$ 的雅克比

- 从Generators角度考虑

- Sim3的Generators，前6个和SE3一样，第7个

$$G_7 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

- 关于每个维度的偏导

$$\frac{\partial \exp(\hat{\zeta})}{\partial \zeta} = [G_1, G_2, G_3, G_4, G_5, G_6, G_7]$$

- 代入计算可得相同结果

视觉SLAM中的应用

- 最小化重投影误差计算Sim3

- e_l 关于 S_{cl} 增量 $\hat{\zeta}$ 的雅克比 (贺一家@中科院自动化所)

- S_{lc} 与 S_{cl} 变化相关联

- S_{lc} 位姿更新 $S_{lc} \leftarrow (\exp(\hat{\zeta}) S_{cl})^{-1} = S_{cl}(\zeta)^{-1}$

- 雅克比

$$\begin{aligned} \frac{\partial e_l(S_{cl}(\zeta)^{-1}, y_c)}{\partial \zeta} \Big|_{\zeta=0} &= - \frac{\partial \hat{z}_l(x)}{\partial x} \Big|_{\tilde{x}=S_{lc}\tilde{y}_c} \cdot \frac{\partial x(S_{cl}(\zeta)^{-1}, y_c)}{\partial \zeta} \Big|_{\zeta=0} \\ &= - \frac{\partial \hat{z}_l(x)}{\partial x} \Big|_{\tilde{x}=S_{lc}\tilde{y}_c} \cdot [I_{3 \times 3} \quad 0_{3 \times 1}] \cdot \frac{\partial S_{cl}(\zeta)^{-1} \cdot \tilde{y}_c}{\partial \zeta} \Big|_{\zeta=0} \end{aligned}$$

- 逆矩阵求导公式

$$\frac{\partial A^{-1}}{\partial a} = -A^{-1} \frac{\partial A}{\partial a} A^{-1}$$

- 后一项化简

$$\frac{\partial S_{cl}(\zeta)^{-1} \cdot \tilde{y}_c}{\partial \zeta} \Big|_{\zeta=0} = - \left[S_{lc} \cdot \frac{\partial S_{cl}(\zeta)}{\partial \zeta} \cdot S_{lc} \cdot \tilde{y}_c \right] \Big|_{\zeta=0} = -S_{lc} \cdot \begin{bmatrix} -\hat{y}_c & I_{3 \times 3} & y_c \\ 0 & 0 & 0 \end{bmatrix}$$

视觉SLAM中的应用

- 最小化重投影误差计算Sim3

- e_l 关于 s_{cl} 增量 $\hat{\zeta}$ 的雅克比（贺一家@中科院自动化所）

- 整体代入

$$\frac{\partial e_l(s_{cl}(\zeta)^{-1}, y_c)}{\partial \zeta} \Big|_{\zeta=0} = - \frac{\partial \hat{z}_c(x)}{\partial x} \Big|_{x=s_{lc}R_{lc}y_c+t_{lc}} \cdot s_{lc}R_{lc} \cdot [\hat{y}_c \quad -I_{3 \times 3} \quad -y_c]$$

$$= J_{y_c}^{e_l} \cdot [\hat{y}_c \quad -I_{3 \times 3} \quad -y_c]$$

- 红色部分是 e_l 关于 y_c 的雅克比 $J_{y_c}^{e_l}$

- 尺度会影响重投影误差？

- 展开上式，尺度相关的最后一列不为0

$$- \begin{bmatrix} \frac{f_u}{x_3} & 0 & -\frac{f_u x_1}{x_3^2} \\ 0 & \frac{f_v}{x_3} & -\frac{f_v x_2}{x_3^2} \end{bmatrix} \cdot (t_{lc} - x) = - \begin{bmatrix} \frac{f_u}{x_3} & 0 & -\frac{f_u x_1}{x_3^2} \\ 0 & \frac{f_v}{x_3} & -\frac{f_v x_2}{x_3^2} \end{bmatrix} t_{lc} = \begin{bmatrix} \frac{f_u t_1}{x_3} - \frac{f_u x_1 t_3}{x_3^2} \\ \frac{f_v t_2}{x_3} - \frac{f_v x_2 t_3}{x_3^2} \end{bmatrix}$$

参考资料

- [1] TUM的Multiple View Geometry公开课
https://www.youtube.com/playlist?list=PLTBdjV_4f-EJn6udZ34tht9EVIW7lbeo4
- [2] 高翔 (清华大学) 博客
<http://www.cnblogs.com/gaoxiang12/p/5137454.html>
- [3] 贺一家 (中科院自动化所) 博客
<http://blog.csdn.net/heyijia0327/article/details/50446140>
- [4] Barfoot, T. D. (2016). *State Estimation for Robotics: A Matrix-Lie-Group Approach*
- [5] Strasdat, H. (2012). *Local accuracy and global consistency for efficient visual slam* (Doctoral dissertation, Department of Computing, Imperial College London).

谢 谢